

1. - ver leiam-review-rl.pdf

A. 1-NN, nearest. O 1-NN é caracterizado pela "Voronoi partition of space" que descreve a fronteira produzida pelo 1-NN algorithm.

B. Um Probabilistic Gaussian Discrimin com matrix de covariança simétrica resulta numa círculo "a volta dos dados"




C. Um Probabilistic Gaussian Discriminant, com matrix de covariança diferente, resulta num elipse "a volta dos dados".



D. Uma decision tree em real-valued inputs cria uma decision boundary que é constituída por rectângulos no input space.

2.



Apesar de os classes não serem linearmente separáveis, podia-se utilizar, por exemplo, uma Neural Network, com hidden layers, com uma função sigmoide na output layer, dado que esta configuração tem um discriminador linear, que irá passar de treino quando o erro chegar a um valor mínimo.

b)

$$P \rightarrow (2, 1)$$

com $k=1$, o elene de P seria B , dado que o vizinho mais próximo é $B \rightarrow (1, 1)$.

Com $k=3$, vizinhos mais próximos: $B(1, 1)$, $A(4, 1)$, $B(0, 0)$,
logo o elene seria B (2B pra 1A)

c. A

$$d_1: \sqrt{(2-0)^2 + (1-0)^2} = \sqrt{4+1} = \sqrt{5} \quad (P \text{ a } B(0,0)) \quad \text{Guarde a menor!}$$

$$d_2: \sqrt{(2-0)^2 + (1-3)^2} = \sqrt{4+4} = \sqrt{8} \quad (P \text{ a } A(0,3))$$

$$d_3: \sqrt{(2-4)^2 + (1-1)^2} = \sqrt{2^2 + 0} = 2 \quad (P \text{ a } A(4,1))$$

Com $k=10$, teríamos como votos: A, B, A, B, B, A, A : logo seria identificado como A , dado que existem mais A s. Contudo, tem-se de atentar que o nosso dataset tem apenas 7 pontos e por isso, ao utilizar um $k=10$, tem-se de certa forma a probabilidade de overfit. Idealmente, o k deve ser inferior ou igual ao número de pontos do nosso dataset, para se poder ter uma aproximação o mais fiel possível.

c) Na prática, uma regra com pouco se sabe sobre o k no algoritmo de k -NN, é fazer $k = \sqrt{n}$, onde n é o número de pontos do nosso dataset.

- Em teoria, quanto pontos em número infinito de amostras, quanto mais o valor de k , melhor é a classificação (mas antes aproximar-se do Bayes em este ótimo). 4 pontos é que todos os k neighbors têm de estar próximos de ponto teste, o que é impossível quando tem um número finito de amostras. Na prática: 1) k deve ser grande para que a taxa de erro seja minimizada (se for demasiado pequeno levam a fronteiras de decisão com muito ruído); 2) k deve ser pequeno o suficiente para que apenas amostras próximas estejam incluídas (se k demasiado grande irá levar a a fronteira demasiado over-smoothed ...). Vale a pena sempre testar a performance do algoritmo com k -NN duplo e verificar qual é que ele tem uma melhor performance em fazer overfit.

d)

Calcular "class means": $\bar{A}_{x_1} = \frac{0+0+4+4}{4} = \frac{8}{4} = 2$

$\bar{A}_{x_2} = \frac{3+(-1)+1+(-2)}{4} = \frac{-1}{4} = -0.25$

$\bar{A} \rightarrow (2, -0.25)$

$\bar{B}_{x_1} = \frac{0+0+1}{3} = \frac{1}{3} = 0.33$

$\bar{B}_{x_2} = \frac{0+(-2)+1}{3} = \frac{-1}{3} = -0.33$

$\bar{B} \rightarrow (0.33, -0.33)$

Para fazer o anigo de cada ponto há que calcular a distância a cada dono:

Ponto	d_A ; \overline{A} (2, -0.25)	d_B ; \overline{B} (0.33, -0.33)
(0, 3)	$\sqrt{(0-2)^2 + (3+0.25)^2} = 3.81$	$\sqrt{(0-0.33)^2 + (3+0.33)^2} = 3.55$ (B)
(0, -3)	$\sqrt{(0-2)^2 + (-3+0.25)^2} = 3.40$	$\sqrt{(0-0.33)^2 + (-3+0.33)^2} = 2.69$ (B)
(4, 1)	$\sqrt{(4-2)^2 + (1+0.25)^2} = 2.36$ (A)	$\sqrt{(4-0.33)^2 + (1+0.33)^2} = 3.90$
(4, -2)	$\sqrt{(4-2)^2 + (-2+0.25)^2} = 2.66$ (A)	$\sqrt{(4-0.33)^2 + (-2+0.33)^2} = 4.03$
(0, 0)	$\sqrt{(0-2)^2 + (0+0.25)^2} = 2.02$	$\sqrt{(0-0.33)^2 + (0+0.33)^2} = 0.47$ (B)
(0, -2)	$\sqrt{(0-2)^2 + (-2+0.25)^2} = 1.66$	$\sqrt{(0-0.33)^2 + (-2+0.33)^2} = 1.70$ (B)
(1, 1)	$\sqrt{(1-2)^2 + (1+0.25)^2} = 1.60$	$\sqrt{(1-0.33)^2 + (1+0.33)^2} = 1.49$ (B)

Atizem a cada dono o ponto com o valor de distância menor!

3.

$$a) J(c) = \sum_{k=1}^K \sum_{i=1}^N n_{ik} \|x_i - \mu_k\|^2$$

3rd Iteração:

centroids e distâncias

Dados

$$c_1 (2, -0.25)$$

$$c_2 (1/3, -1/3)$$

(0, 3)	3.81	3.35 (c_2)
(0, -3)	3.40	2.69 (c_2)
(4, 1)	2.36 (c_1)	3.90
(4, -2)	2.66 (c_1)	4.03
(0, 0)	2.02	0.47 (c_2)
(0, -4)	2.66	1.70 (c_2)
(1, 1)	1.60	1.49 (c_2)

Nota iterat, a partir de um valor o seguinte valor:

$$J(c) = \|2.36\|^2 + \|2.66\|^2 + (3.35)^2 + (2.69)^2 + (0.47)^2 + (1.70)^2 + (1.49)^2 = 36.4348$$

2^{da} Iteração

1º passo: Calcular Novos Centróides:

$$C_1 = \frac{4 + 4}{2} = 4$$

$$C_2 = \frac{-2 + 1}{2} = -0.5$$

$$C_1 \rightarrow (4, -0.5)$$

$$C_{1L} = \frac{0+0+0+0+1}{5} = 0.20$$

$$C_{2L} = \frac{3-3+0-2+1}{5} = -0.20$$

2º passo: Calcular distâncias:

$$C_1 (4, -0.5)$$

$$C_2 (0.20, -0.20)$$

$$(0, 3) \quad 5.32$$

$$3.21 \quad (C_2)$$

$$(0, -3) \quad 4.72$$

$$4.81 \quad (C_2)$$

$$(4, 1) \quad 1.5 \quad (C_1)$$

$$3.98$$

$$(4, -2) \quad 1.5 \quad (C_1)$$

$$4.20$$

$$(0, 0) \quad 4.03$$

$$0.28 \quad (C_2)$$

$$(0, -2) \quad 4.27$$

$$1.81 \quad (C_2)$$

$$(1, 1) \quad 3.35$$

$$1.44 \quad (C_2)$$

Cálculo do valor de $J(c)$, neste iteração:

$$J(c) = (1.5)^2 + (1.5)^2 + (3.41)^2 + (2.81)^2 + (0.28)^2 + (1.81)^2 \\ + (1.47)^2 = 28.1283$$

5)

$$\text{The } L(\Delta) = \sum_{i=1}^n \|x_i - \mu_k^{(i)}\|^2 = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

k-means is fundamentally a coordinate descent algorithm. Coordinate descent serves to minimize a multivariate function along one direction at a time. The inner-loop of k-means repeatedly minimizes the function with respect to k while holding μ fixed and then minimizes with respect to μ while holding k fixed. This means the function must monotonically decrease and that values must converge.

4.

i) False. SVMs will always try to improve the margin between points in the input space, so, it will achieve less accuracy than Perceptron, due to the fact that the Perceptron algorithm only stops until it has correctly classified all the training data, i.e., it overfits in the true defn.

ii) False. They actually achieve higher accuracy than Perceptron on the test set, regarding the fact that, during training, the SVM algorithm only maximizes the margin between classes, while the Perceptron overfits on the training set which will lead to a worse performance on the test set. Kernels, however, are useful to solve non-linear separation problems, but will not greatly better performance.

5.

a) we can use the normal equations method:

Write the cost function in matrix form:

$$Z(w, s) = \frac{1}{2} \sum_{n=1}^N (y_i - f(x_i))^2$$

$$= \frac{1}{2} (Xw - y)^T (Xw - y) = \frac{1}{2} (w^T X^T X w - w^T X^T y + y^T X w + y^T y)$$

To minimize $Z(w, s)$, take derivative and set to zero:

$$\frac{\partial Z}{\partial w} = -X^T y + X^T X w = 0$$

$$\boxed{X^T X w = X^T y}$$

Portanto: $X = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 1 & 2 \end{bmatrix}$, $w = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$, $y = \begin{bmatrix} 2.5 \\ 4 \\ 3.5 \end{bmatrix}$

So, the normal equations:

$$X^T X w = X^T y$$

$$\begin{bmatrix} 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}_{2 \times 3} \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 1 & 2 \end{bmatrix}_{3 \times 2} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}_{2 \times 1} = \begin{bmatrix} 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}_{2 \times 3} \begin{bmatrix} 2.5 \\ 4 \\ 3.5 \end{bmatrix}_{3 \times 1}$$

$$\begin{bmatrix} 6 & 5 \\ 5 & 6 \end{bmatrix}_{2 \times 2} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}_{2 \times 1} = \begin{bmatrix} 14 \\ 13.5 \end{bmatrix}_{2 \times 1}$$

$$\begin{bmatrix} 6w_1 + 5w_2 \\ 5w_1 + 6w_2 \end{bmatrix}_{2 \times 1} = \begin{bmatrix} 14 \\ 13.5 \end{bmatrix}_{2 \times 1}$$

Resolvendo o sistema de Eqs:

$$\begin{cases} 6w_1 + 5w_2 = 14 \\ 5w_1 + 6w_2 = 13,5 \end{cases} \Rightarrow \begin{cases} 6w_1 = 14 - 5w_2 \\ \text{---} \end{cases} \Rightarrow \begin{cases} w_1 = \frac{14 - 5w_2}{6} \\ 5\left(\frac{14 - 5w_2}{6}\right) + 6w_2 = 13,5 \end{cases}$$

$$\Rightarrow \begin{cases} \frac{70 - 25w_2}{6} + 6w_2 = 13,5 \\ \text{---} \end{cases} \Rightarrow \begin{cases} 70 - 25w_2 + 36w_2 = 81 \\ \text{---} \end{cases} \Rightarrow \begin{cases} 11w_2 = 11 \\ \text{---} \end{cases}$$

$$\begin{cases} w_1 = \frac{14 - 5(1)}{6} \\ w_2 = 1 \end{cases} \Rightarrow \begin{cases} w_1 = \frac{9}{6} \\ w_2 = 1 \end{cases} \Rightarrow \begin{cases} w_1 = 1,5 \\ w_2 = 1 \end{cases}$$

Logo, o modelo é: $\hat{y} = w_1 x_1 + w_2 x_2$

$$\Rightarrow \hat{y} = 1,5(x_1) + (1)x_2$$

$$\boxed{\hat{y} = 1,5x_1 + x_2}$$

b)

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = a_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + a_2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + a_3 \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

Resolvendo o Sistema de Equações:

$$\begin{cases} w_1: a_1 + 2a_2 + a_3 \\ w_2: a_1 + a_2 + 2a_3 \end{cases} \stackrel{(-)}{\sim} \begin{cases} 1.5: a_1 + 2a_2 + a_3 \\ 1: a_1 + a_2 + 2a_3 \end{cases} \stackrel{(-)}{\sim} \begin{cases} a_1 = 1.5 - 2a_2 - a_3 \\ \end{cases}$$

$$\begin{cases} 1: (1.5 - 2a_2 - a_3) + a_2 + 2a_3 \\ 1: 1.5 - a_2 + a_3 \end{cases} \stackrel{(-)}{\sim} \begin{cases} a_1 = \frac{3}{2} - 2\left(\frac{1}{2} + a_3\right) - a_3 \\ a_2 = \frac{1}{2} + a_3 \end{cases}$$

$$\begin{cases} a_1 = \frac{3}{2} - 1 - 2a_3 - a_3 \\ a_2 = \frac{1}{2} + a_3 \end{cases} \stackrel{(-)}{\sim} \begin{cases} a_1 = \frac{5}{2} - \frac{3}{2} - 3a_3 \\ a_2 = \frac{1}{2} + a_3 \end{cases} \stackrel{(-)}{\sim} \begin{cases} a_1 = +\frac{1}{2} - 3a_3 \\ a_2 = \frac{1}{2} + a_3 \end{cases}$$

Arbitrando $a_3: a_3 = 1$

$$a_1 = +\frac{1}{2} - 3(1) = +\frac{1}{2} - \frac{6}{2} = -\frac{5}{2}$$

$$a_2 = \frac{1}{2} + 1 = \frac{1}{2} + \frac{2}{2} = \frac{3}{2}$$

$$\begin{aligned} a_1 &= -\frac{5}{2} \\ a_2 &= \frac{3}{2} \\ a_3 &= 1 \end{aligned}$$

Testando

$$w_1: a_1 + 2a_2 + a_3 \stackrel{(-)}{\sim} 1.5 = -\frac{5}{2} + 2\left(\frac{3}{2}\right) + 1 \stackrel{(-)}{\sim} 1.5 = -\frac{5}{2} + \frac{6}{2} + \frac{2}{2}$$

$$\stackrel{(-)}{\sim} 1.5 = \frac{3}{2} \quad (\checkmark)$$

$$w_2: a_1 + a_2 + 2a_3 \stackrel{(-)}{\sim} 1 = -\frac{5}{2} + \frac{3}{2} + 2(1) \stackrel{(-)}{\sim} 1 = -\frac{2}{2} + \frac{4}{2} \stackrel{(-)}{\sim} 1 = \frac{2}{2} \quad (\checkmark)$$

e) reescrevendo, $\text{span}(v_1, v_2, \dots, v_n) = \{c_1 v_1 + c_2 v_2 + \dots + c_n v_n\}$,
 $c_i \in \mathbb{K}, i \in \{1, \dots, n\}$

se derivamos a função

$$\min_w \sum_{i=1}^n L(w^T x_i, y_i) + \lambda \|w\|^2$$

$$\min_w L(W X^T, y) + \lambda \|w\|^2$$

em que X tem dimensão $n \times d$, X^T tem dimensão $d \times n$
 y tem dimensão $n \times 1$

W tem dimensão $d \times 1$

o problema é dado por:

$$\text{Span}(x_1, x_2, x_3, \dots, x_n) = \{a_1 x_1 + a_2 x_2 + a_3 x_3 + \dots + a_n x_n\}$$

em cada iteração

$$a_i \in \mathbb{K}, i \in \{1, \dots, n\}$$

o problema é escrito

em w de forma com $x_i w_i = y_i$

para $a_i x_i = y_i$ | ou isto se interpreta que queremos o
 número de variáveis n , ou seja w só tem n
 entre colunas em de 1 a n

feito por um coeficiente a_i ; $x_i = a_i \begin{bmatrix} 1 \\ \vdots \\ d \end{bmatrix}$, isto permite que multipliquemos por antes as dimensões do vetor.

d. Sabendo o modelo do cin, se fixarmos apenas a_i o modelo fica do tipo:

$$w_i = \begin{bmatrix} w_1 \\ \vdots \\ w_d \end{bmatrix} = \sum_{i=1}^n a_i x_i$$

$$(c) \begin{bmatrix} w_1 \\ \vdots \\ w_d \end{bmatrix} = a_1 \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} + \dots + a_n \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix}$$

Sample 1 Sample n


Uma das opções seria usar opções inteiramente diferentes:

- d é pequeno, isto é, quanto os atributos existentes de cada amostra são um número relativamente pequeno, tentando ver se os vetores também não são demasiado extensos;
- n é pequeno, dado que se n for um número extremamente grande, ter-se-ia um custo de calcular os coeficientes e modelar em relação com os coeficientes para cada par.
- Por uma opção acima, obter dados em situações em que o sistema de quântica seja impossível e/ou indefinido.

um iteração interessante é quando $n = 1$, pois fixamos parte do sistema de eqs inicial e definindo de qual se tem, no caso que esta seja uma derivada complexa, que computacionalmente pode tornar-se expensivo!

8.

a) Estes pontos de observação e cujas possibilidades de ocorrência dependem dos estados anteriores. Portanto, tem de assumir que cada repetição observada é produzida através do uptake de diversos transpos entre estados, a digressão de - estado:



$$P(\text{injury} | \text{climb}) = 0.8$$

$$P(\text{not injury} | \text{climb}) = 0.2$$

$$P(\text{injury} | \text{not climb}) = 0.1$$

$$P(\text{not injury} | \text{not climb}) = 0.9$$

The observation:

Monday → Tuesday → Wednesday

injury injury ~ injury Injury Not injury

$\begin{bmatrix} 0 & 1 \end{bmatrix}$

hence: python:

no error:

python code

Transition Matrix:

$$\begin{matrix} & \text{State 1} & \text{State 2} \\ \text{State 1} & \begin{bmatrix} 0.9 & 0.9 \end{bmatrix} \\ \text{State 2} & \begin{bmatrix} 0.9 & 0.4 \end{bmatrix} \end{matrix}$$

Initial probs:

$\begin{bmatrix} 0.98 & 0.02 \end{bmatrix}$

State 1 State 2

Emission probabilities:

$$\begin{matrix} & \text{injury} & \text{not injury} \\ \text{State 1} & \begin{bmatrix} 0.8 & 0.1 \end{bmatrix} \\ \text{State 2} & \begin{bmatrix} 0.2 & 0.9 \end{bmatrix} \end{matrix}$$

$$\begin{matrix} & \text{injury} & \text{not injury} \\ \text{State 1} & \begin{bmatrix} 0.8 & 0.2 \end{bmatrix} \\ \text{State 2} & \begin{bmatrix} 0.1 & 0.9 \end{bmatrix} \end{matrix}$$

Time to compute a forward algorithm: slide 53/60

The joint probability is: 0.20

lecture 1)

7.

Bernoulli Distribution


$$D(n) \begin{cases} 1-p & \text{for } n=0 \\ p & \text{for } n=1 \end{cases}$$

$$P(n) \begin{cases} 1-p & , n=0 \\ p & , n=1 \end{cases}$$

Initial probs

$$\begin{bmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{bmatrix}$$

$s_1 \quad s_2 \quad s_3$



T matrix

$$\begin{bmatrix} \frac{1}{3} & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{2} \end{bmatrix}$$

Emission Prob Matrix

$$\begin{bmatrix} 1-p & p & p \\ p & 1-p & p \end{bmatrix}$$